260102/sql/Main_Quest_1

11-2. 데이터 불러오기

▼ 데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
SELECT *
FROM modulabs_project.data
LIMIT 10;
```

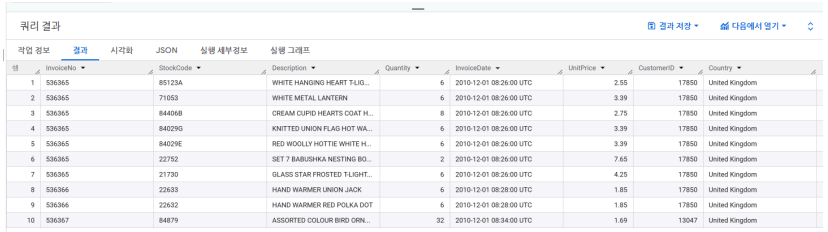

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC	2.55	17850	United Kingdom
2	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
3	536365	84406B	CREAM CUPID HEARTS COAT H...	8	2010-12-01 08:26:00 UTC	2.75	17850	United Kingdom
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-01 08:26:00 UTC	7.65	17850	United Kingdom
7	536365	21730	GLASS STAR FROSTED T-LIGHT...	6	2010-12-01 08:26:00 UTC	4.25	17850	United Kingdom
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom
9	536366	22632	HAND WARMER RED POLKA DOT	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom
10	536367	84879	ASSORTED COLOUR BIRD ORN...	32	2010-12-01 08:34:00 UTC	1.69	13047	United Kingdom

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
SELECT *
FROM modulabs_project.data;
```

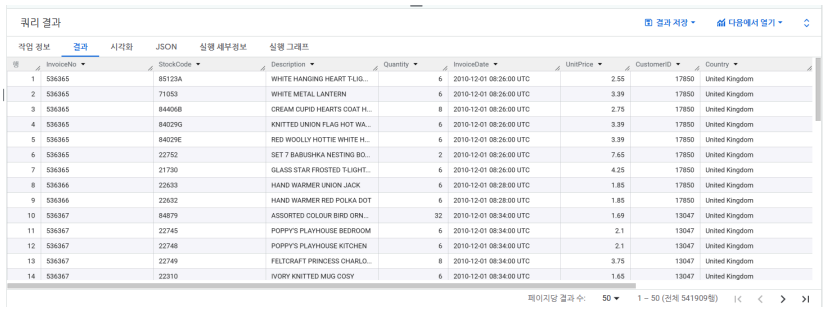

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC	2.55	17850	United Kingdom
2	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
3	536365	84406B	CREAM CUPID HEARTS COAT H...	8	2010-12-01 08:26:00 UTC	2.75	17850	United Kingdom
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-01 08:26:00 UTC	7.65	17850	United Kingdom
7	536365	21730	GLASS STAR FROSTED T-LIGHT...	6	2010-12-01 08:26:00 UTC	4.25	17850	United Kingdom
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom
9	536366	22632	HAND WARMER RED POLKA DOT	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom
10	536367	84879	ASSORTED COLOUR BIRD ORN...	32	2010-12-01 08:34:00 UTC	1.69	13047	United Kingdom
11	536367	22745	POPPY'S PLAYHOUSE BEDROOM	6	2010-12-01 08:34:00 UTC	2.1	13047	United Kingdom
12	536367	22748	POPPY'S PLAYHOUSE KITCHEN	6	2010-12-01 08:34:00 UTC	2.1	13047	United Kingdom
13	536367	22749	FELTCRAFT PRINCESS CHARLO...	8	2010-12-01 08:34:00 UTC	3.75	13047	United Kingdom
14	536367	22310	IVORY KNITTED MUG COSY	6	2010-12-01 08:34:00 UTC	1.65	13047	United Kingdom

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
SELECT
  COUNT (InvoiceNo) AS count_InvoiceNo,
  COUNT (StockCode) AS count_StockCode,
  COUNT (Description) AS count_Description,
  COUNT (Quantity) AS count_Quantity,
  COUNT (InvoiceDate) AS count_InvoiceDate,
  COUNT (UnitPrice) AS count_UnitPrice,
  COUNT (CustomerID) AS count_CustomerID,
  COUNT (Country) AS count_Country,
FROM modulabs_project.data;
```

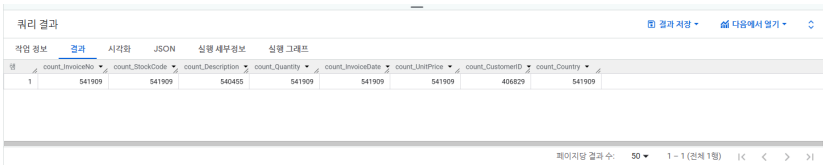

행	count_InvoiceNo	count_StockCode	count_Description	count_Quantity	count_InvoiceDate	count_UnitPrice	count_CustomerID	count_Country
1	541909	541909	540455	541909	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

▼ 컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**
  - **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
-- 각 행별 결측치 유뮤 확인
SELECT
  COUNTIF(InvoiceNo IS NULL) AS missing_InvoiceNo,
  COUNTIF(StockCode IS NULL) AS missing_StockCode,
  COUNTIF(Description IS NULL) AS missing_Description,
  COUNTIF(Quantity IS NULL) AS missing_Quantity,
  COUNTIF(InvoiceDate IS NULL) AS missing_InvoiceDate,
  COUNTIF(UnitPrice IS NULL) AS missing_UnitPrice,
  COUNTIF(CustomerID IS NULL) AS missing_CustomerID,
  COUNTIF(Country IS NULL) AS missing_Country,
FROM modulabs_project.data;

-- 결측치 비율 계산 후 UNION ALL을 통해 결측치 합치기
SELECT'Description',
    -- Description의 결측치 비율 백분율로 계산 (소수점 둘째 자리 반올림)
    -- SUM(CASE WHEN...)을 사용해 NULL이면 1을 더하고, 이를 전체 행 수로 나눈 뒤 100을 곱해 백분율 산출 (소수점 둘째 자리 반올림)
    ROUND(SUM(CASE WHEN Description IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `modulabs_project.data`

UNION ALL --위아래의 쿼리 결과 집합을 하나로 통합

SELECT'CustomerID',
    --  CustomerID의 결측치 비율 백분율로 계산 (소수점 둘째 자리 반올림)
    ROUND(SUM(CASE WHEN CustomerID IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `modulabs_project.data`;
```

▼ 결측치 처리 전략

- `StockCode = '85123A'` **의** `Description` **을 추출하는 쿼리문을 작성하기**

```
-- 단순 추출 쿼리 (현상 파악용)
-- StockCode = '85123A'의 Description을 추출하는 쿼리문을 작성
SELECT Description
FROM modulabs_project.data
WHERE StockCode = '85123A';
ORDER BY record_count ASC; -- 개수가 적은 순서대로 정렬

--------------------------------------------------------------------------------
-- [추가수행] 데이터 카운트 기반 분석 쿼리 (데이터 정제 및 의사결정용)
-- 필요한 이유:
-- 1. 데이터 무결성 확인: 동일한 StockCode에 여러 Description이 섞여 있는지(데이터 오염) 한눈에 파악 가능
-- 2. 대표성 판단: 가장 많이 사용된 데이터를 대표값으로 채택 등
-- 3. 이상치 탐지: 개수가 현저히 적은(예: 1건) Description은 오타나 일시적 오류일 가능성 높음
SELECT
    Description,
    COUNT(*) AS record_count
```

```
FROM `modulabs_project.data`
WHERE StockCode = '85123A'
GROUP BY Description        -- 개수를 세기 위해 그룹화 추가
ORDER BY record_count ASC;    -- 개수가 적은 순서대로 정렬
```

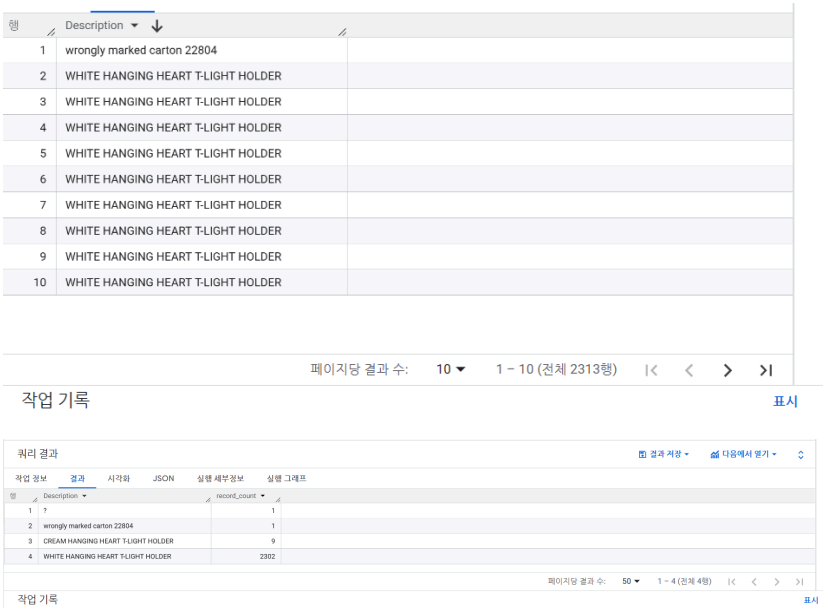

▼ 결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
-- 테이블에서 결측치가 포함된 행 삭제
DELETE FROM `modulabs_project.data` -- 삭제 작업 수행할 테이블 지정
WHERE
  CustomerID IS NULL   -- 조건 1: CustomerID 컬럼에 값이 없는 경우
  OR                   -- 조건 1, 2 중 하나만 만족해도 삭제
  Description IS NULL; -- 조건 2: Description 컬럼에 값이 없는 경우
```

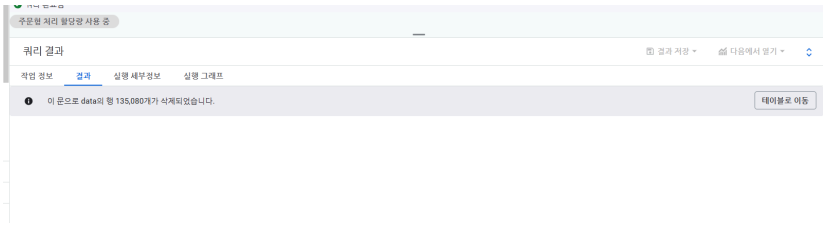

11-5. 데이터 전처리(2): 중복값 처리

▼ 중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
-- 중복된 행의 갯수 구해보기
SELECT
   -- 서브쿼리에서 넘어온 '중복 Group'들의 총 개수 계산
   COUNT(*) AS total_duplicate_groups
FROM (
   -- 데이터 그룹화 테이블의 8개 컬럼을 기준으로 삼아, 값이 모두 똑같은 행들을
   -- 하나의 Group 에 모으고 그 개수(cnt) 계산
   SELECT
      COUNT(*) AS cnt
```

```
    FROM `modulabs_project.data`
    GROUP BY
        InvoiceNo, StockCode, Description, Quantity,
        InvoiceDate, UnitPrice, CustomerID, Country

    -- Group에 담긴 행의 개수가 2개 이상인 것들만 산출
    HAVING COUNT(*) > 1
) AS sub;
```

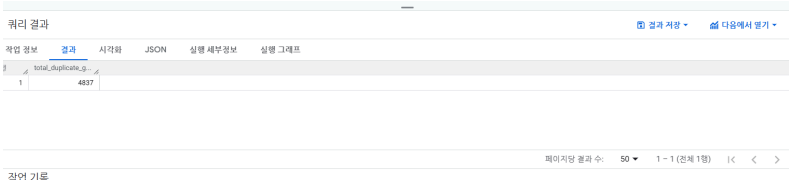

▼ 중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
CREATE OR REPLACE TABLE `modulabs_project.data` AS
SELECT DISTINCT * -- 모든 컬럼(*)을 비교하여 완벽하게 일치하는 중복 행을 제거하고 1건씩만 추출
FROM `modulabs_project.data`;

-- 업데이트 결과 확인
SELECT
  COUNT(*)
FROM modulabs_project.data;
```

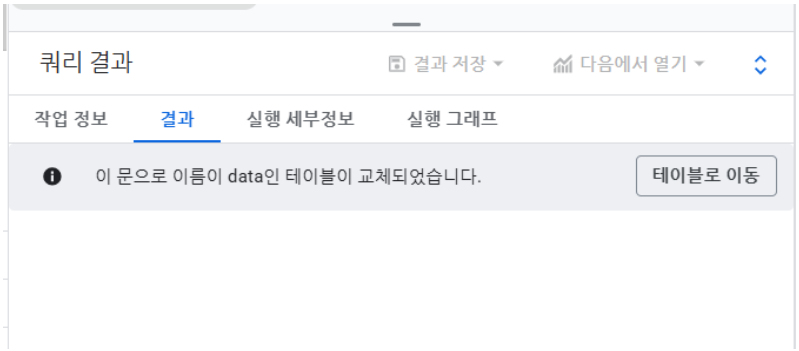

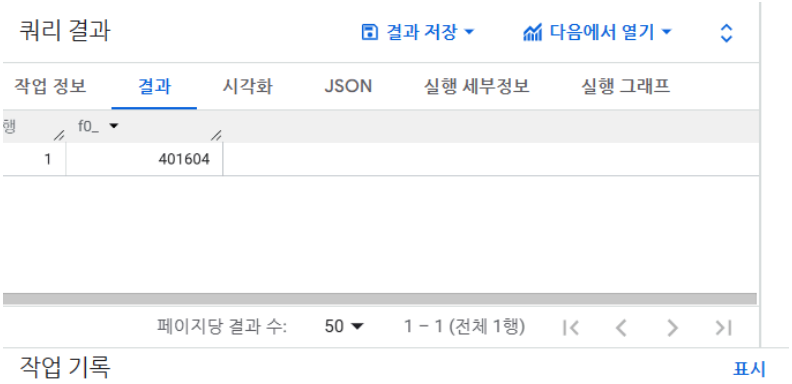

11-6. 데이터 전처리(3): 오류값 처리

▼ `InvoiceNo` 살펴보기

- **고유(unique)한 `InvoiceNo`의 개수를 출력하기**

```
SELECT COUNT(DISTINCT InvoiceNo) -- InvoiceNo 컬럼에서 중복을 제거한 후 개수 카운트
FROM modulabs_project.data;
```

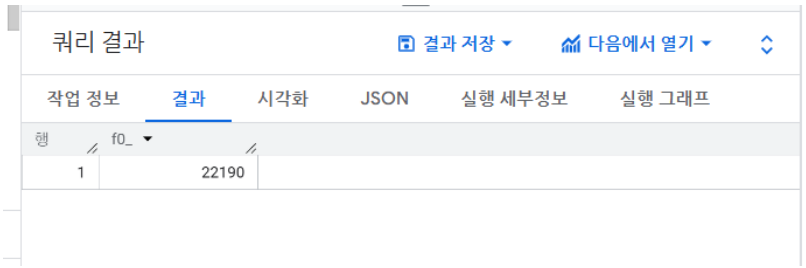

- **고유한 `InvoiceNo`를 앞에서부터 100개를 출력하기**

```
SELECT DISTINCT InvoiceNo
FROM modulabs_project.data
LIMIT 100;
```

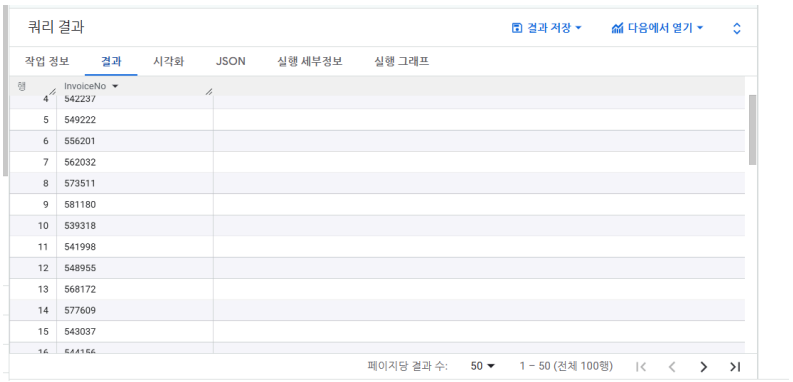

- `InvoiceNo`가 **'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)**

```
SELECT *
FROM modulabs_project.data
WHERE InvoiceNo LIKE 'C%'
LIMIT 100;
```

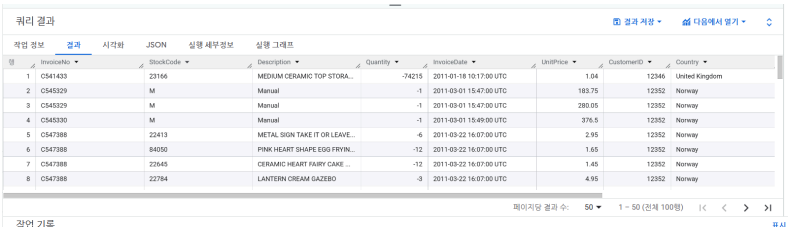

- **구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지**

```
SELECT
 ROUND(
```

```
    SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) -- 취소 건수
    / COUNT(*) -- 전체 건수
    * 100, -- 백분율 단위로 변환
    1 -- 소수점 첫째 자리까지 반올림
  ) AS Canceled_rate
FROM `modulabs_project.data`;
```

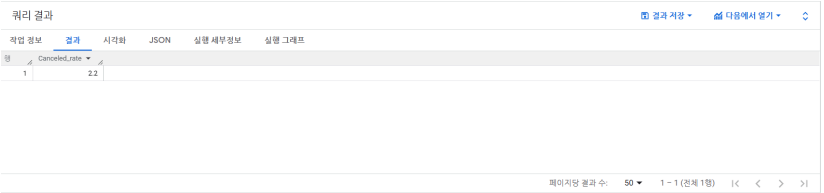

▼ StockCode 살펴보기

- **고유한 StockCode 의 개수를 출력하기**

```
SELECT COUNT(DISTINCT StockCode) -- StockCode 컬럼에서 중복을 제거한 후 개수 카운트
FROM modulabs_project.data;
```

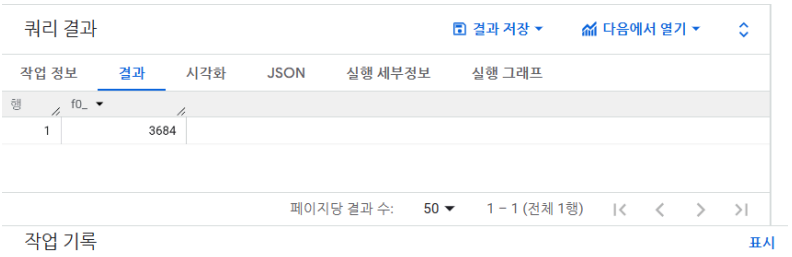

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 StockCode 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM modulabs_project.data
GROUP BY StockCode
ORDER BY sell_cnt DESC
LIMIT 10;
```

  - **StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**

- **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  -- 각 StockCode 내에 포함된 '숫자의 개수'를 계산
  SELECT StockCode,
    -- 전체 길이에서 숫자를 제거한 길이를 빼서 '숫자가 몇 개였는지' 계산
    LENGTH(StockCode) -- 1. 원본 StockCode의 전체 글자 수
    -
    LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) --  2. 숫자(0-9)를 모두 제거한 후 남은 글자 수
    AS number_count -- 위 계산 결과(1-2)를 number_count라는 이름의 컬럼으로 생성
  FROM modulabs_project.data
)
WHERE number_count >= 0 AND number_count <= 1;
```

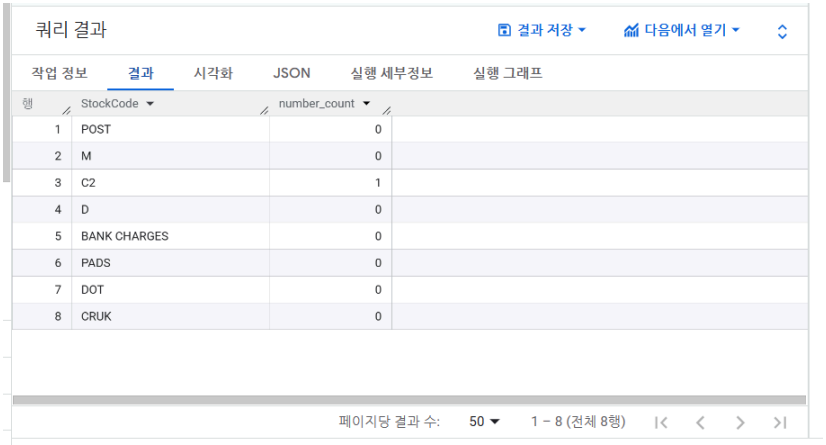

행	StockCode	number_count
1	POST	0
2	M	0
3	C2	1
4	D	0
5	BANK CHARGES	0
6	PADS	0
7	DOT	0
8	CRUK	0

- **`StockCode`의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
SELECT
  ROUND(SUM(CASE WHEN
  (LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', ''))) <= 1
  THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
  AS StockCode_number_count_ratio
FROM `modulabs_project.data`;
```

행	StockCode_numb...
1	0.48

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
DELETE FROM modulabs_project.data
WHERE StockCode IN (
  SELECT DISTINCT StockCode
  FROM (SELECT  StockCode,
          (LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', ''))) AS number_count
```

```
    FROM modulabs_project.data)
WHERE number_count <= 1);
```

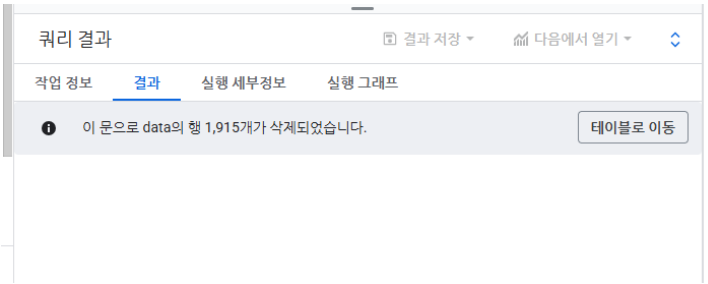

▼ Description 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT Description, COUNT(*) AS description_cnt
FROM modulabs_project.data
GROUP BY Description
ORDER BY Description_cnt DESC
LIMIT 30;
```

행	Description	description_cnt
1	WHITE HANGING HEART T-LIGHT HOLDER	2058
2	REGENCY CAKESTAND 3 TIER	1894
3	JUMBO BAG RED RETROSPOT	1659
4	PARTY BUNTING	1409
5	ASSORTED COLOUR BIRD ORNAMENT	1405
6	LUNCH BAG RED RETROSPOT	1345
7	SET OF 3 CAKE TINS PANTRY DESIGN	1224
8	LUNCH BAG BLACK SKULL.	1099

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
DELETE
FROM modulabs_project.data
WHERE
  Description IN ('Next Day Carriage', 'High Resolution Image');
```

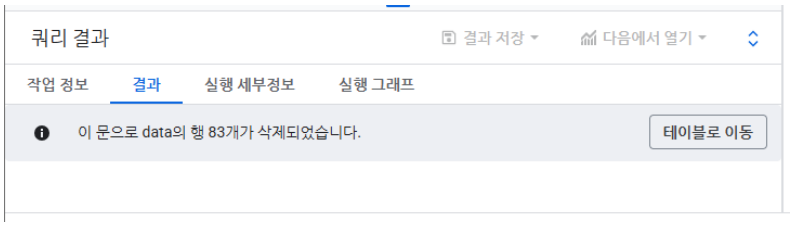

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE modulabs_project.data AS
SELECT
  * EXCEPT (Description),-- 기존 Description은 제외하고
  UPPER(Description) AS Description -- 대문자로 변환한 Description을 새로 추가
FROM modulabs_project.data;
```

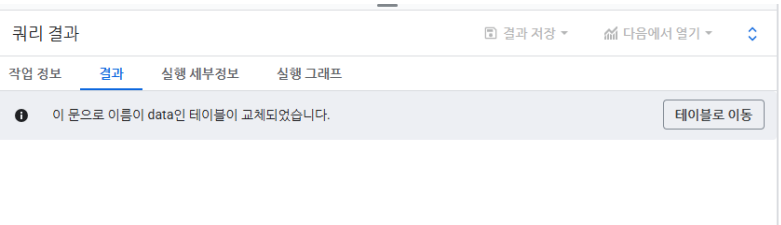

▼ UnitPrice 살펴보기

- **UnitPrice 의 최솟값, 최댓값, 평균을 구하기**

```
SELECT
   MIN(UnitPrice) AS min_price,
   MAX(UnitPrice) AS max_price,
   AVG(UnitPrice) AS avg_price
FROM modulabs_project.data;
```

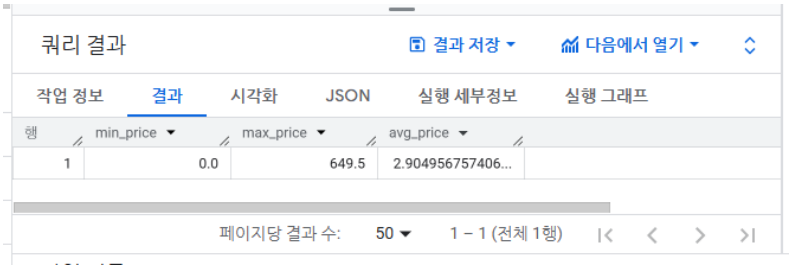

- **단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기**

```
SELECT
   COUNT(*) AS cnt_quantity,
   MIN(Quantity) AS min_quantity,
   MAX(Quantity) AS max_quantity,
   AVG(Quantity) AS avg_quantity
FROM modulabs_project.data
WHERE UnitPrice = 0
```

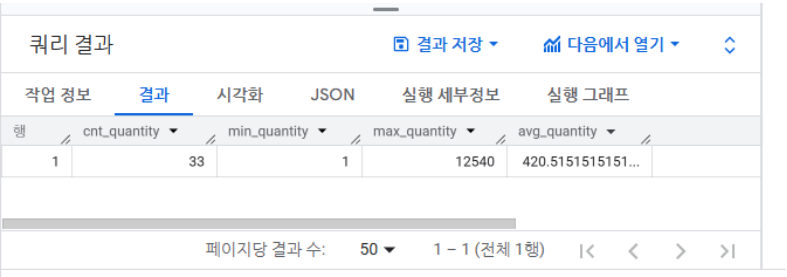

- **UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기**

```
CREATE OR REPLACE TABLE modulabs_project.data AS
SELECT *
```

```
FROM modulabs_project.data
WHERE UnitPrice > 0;
```

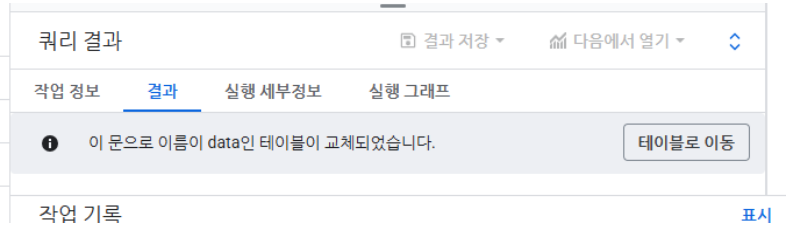

11-7. RFM 스코어

▼ Recency

- `InvoiceDate` **컬럼을 연월일 자료형으로 변경하기**

```
SELECT CAST(InvoiceDate AS DATE) AS InvoiceDay, *
FROM modulabs_project.data;
```

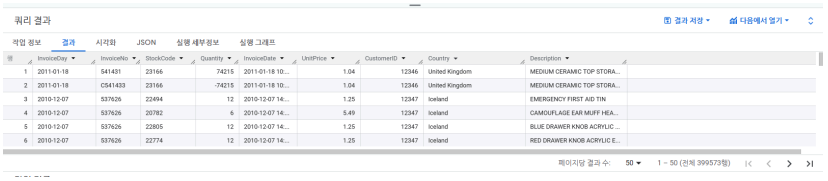

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT
  MAX(CAST(InvoiceDate AS DATE)) OVER() AS most_recent_date,
  CAST(InvoiceDate AS DATE) AS InvoiceDay,
  *
FROM modulabs_project.data;
```

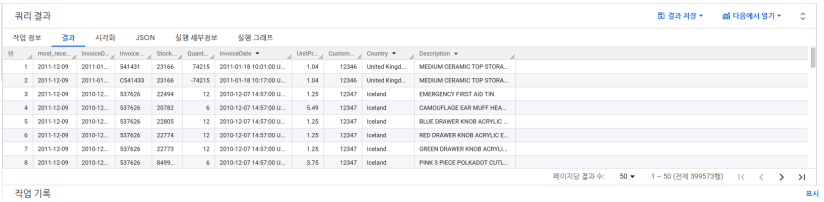

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
SELECT
   CustomerID,
   MAX(CAST(InvoiceDate AS DATE)) AS InvoiceDay
FROM modulabs_project.data
GROUP BY CustomerID;
```

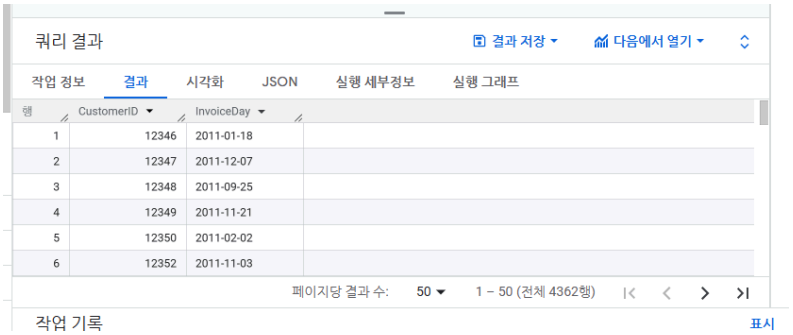

- **가장 최근 일자(`most_recent_date`)와 유저별 마지막 구매일(`InvoiceDay`)간의 차이를 계산하기**

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM modulabs_project.data
  GROUP BY CustomerID
);
```

  - **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE modulabs_project.user_r AS
SELECT
  CustomerID, -- 전체 데이터 마감일에서 각 고객의 마지막 구매일을 뺀 일수 계산
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  -- 고객별 가장 최근 구매 날짜(InvoiceDay)추출 서브쿼리
  SELECT
    CustomerID, MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM modulabs_project.data
  GROUP BY CustomerID
);
```

project-573d05ee-0149-4ee2-b90 / Da

user_r 쿼리 다음에서 열

스키마 세부정보 미리보기 테이

행	CustomerID	recency
1	14446	0
2	12423	0
3	13069	0
4	15311	0
5	15910	0
6	14397	0
7	13777	0
8	17428	0
9	16954	0
10	14441	0

▼ Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT
  CustomerID,
  COUNT(DISTINCT InvoiceNo) AS purchase_cnt -- 동일한 주문 번호(InvoiceNo)를 중복 없이 카운트하여 실제 주문 횟수 계산
FROM modulabs_project.data
GROUP BY CustomerID;
```

쿼리 결과 결과 저장 다음에서 열기

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	purchase_cnt
1	12346	2
2	12347	7
3	12348	4
4	12349	1
5	12350	1
6	12352	8

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT
  CustomerID,
  SUM (Quantity) AS item_cnt
FROM modulabs_project.data
GROUP BY CustomerID;
```

쿼리 결과 결과 저장 다음에서 열기

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	item_cnt
1	12346	0
2	12347	2458
3	12348	2332
4	12349	630
5	12350	196
6	12352	463

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
-- 전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 user_rf라는 이름의 테이블에 저장하기

CREATE OR REPLACE TABLE modulabs_project.user_rf AS
-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
  SELECT CustomerID, COUNT(DISTINCT InvoiceNo) AS purchase_cnt
  FROM modulabs_project.data
  GROUP BY CustomerID),
-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
  SELECT CustomerID, SUM(Quantity) AS item_cnt
  FROM modulabs_project.data
  GROUP BY CustomerID)
-- 기존의 user_r에 (1)과 (2)를 통합
SELECT pc.CustomerID, pc.purchase_cnt, ic.item_cnt, ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN modulabs_project.user_r AS ur
  ON pc.CustomerID = ur.CustomerID;
```

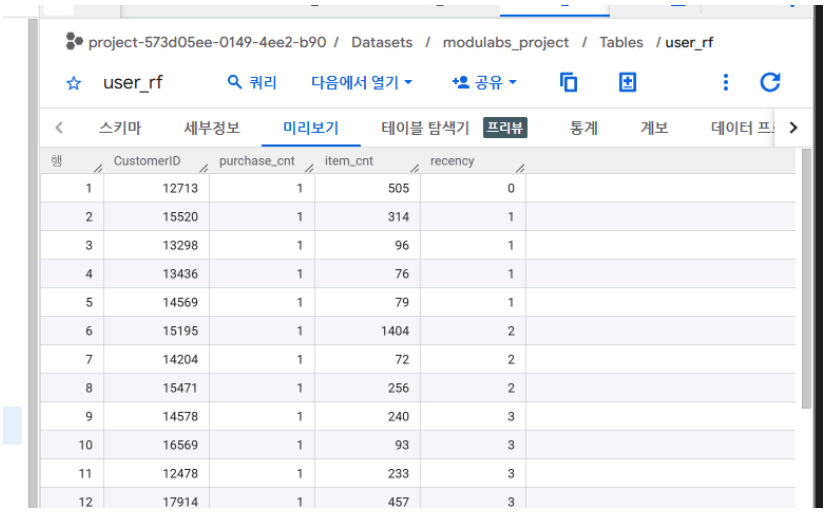

project-573d05ee-0149-4ee2-b90 / Datasets / modulabs_project / Tables / user_rf

user_rf 쿼리 다음에서 열기 공유

스키마 세부정보 미리보기 테이블 탐색기 프리뷰 통계 계보 데이터 프

행	CustomerID	purchase_cnt	item_cnt	recency
1	12713	1	505	0
2	15520	1	314	1
3	13298	1	96	1
4	13436	1	76	1
5	14569	1	79	1
6	15195	1	1404	2
7	14204	1	72	2
8	15471	1	256	2
9	14578	1	240	3
10	16569	1	93	3
11	12478	1	233	3
12	17914	1	457	3

▼ Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
SELECT CustomerID,
  ROUND(SUM (Quantity * UnitPrice), 0) AS user_total
FROM modulabs_project.data
GROUP BY CustomerID;
```

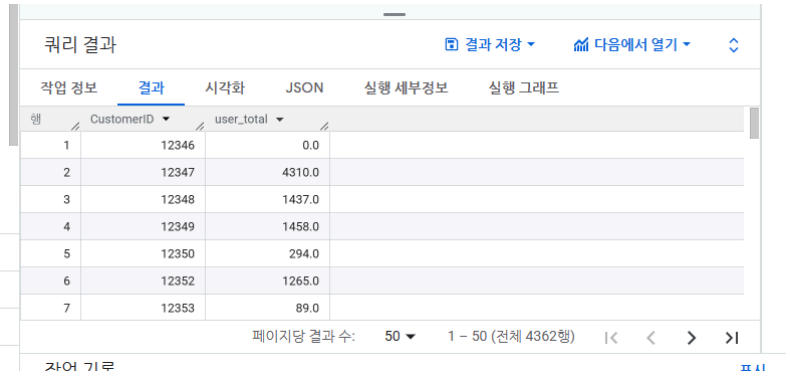

행	CustomerID	user_total
1	12346	0.0
2	12347	4310.0
3	12348	1437.0
4	12349	1458.0
5	12350	294.0
6	12352	1265.0
7	12353	89.0

- **고객별 평균 거래 금액 계산**
  - **1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후,**
  - **2) `purchase_cnt` 로 나누어서**
  - **3) `user_rfm` 테이블로 저장하기**

```
CREATE OR REPLACE TABLE modulabs_project.user_rfm AS
SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  ROUND(ut.user_total / rf.purchase_cnt, 0) AS user_average -- 총 지출액/주문 횟수
FROM modulabs_project.user_rf rf
LEFT JOIN (
  -- 고객 별 총 지출액
  SELECT
    CustomerID,
    ROUND(SUM(Quantity * UnitPrice), 0) AS user_total
  FROM modulabs_project.data
  GROUP BY CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;
```

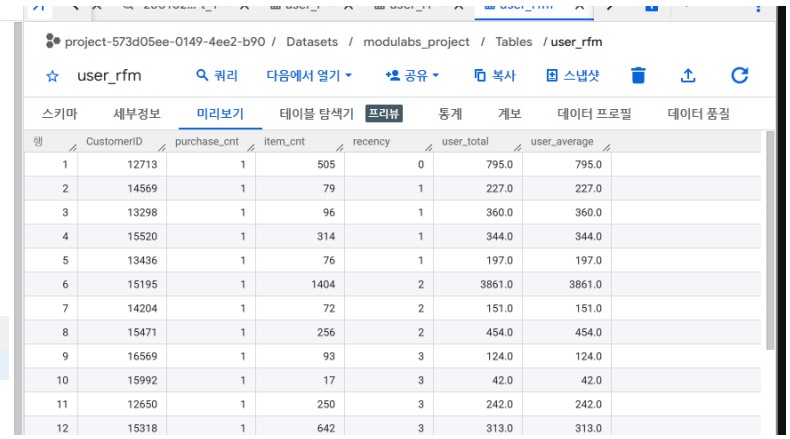

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	795.0	795.0
2	14569	1	79	1	227.0	227.0
3	13298	1	96	1	360.0	360.0
4	15520	1	314	1	344.0	344.0
5	13436	1	76	1	197.0	197.0
6	15195	1	1404	2	3861.0	3861.0
7	14204	1	72	2	151.0	151.0
8	15471	1	256	2	454.0	454.0
9	16569	1	93	3	124.0	124.0
10	15992	1	17	3	42.0	42.0
11	12650	1	250	3	242.0	242.0
12	15318	1	642	3	313.0	313.0

▼ RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
SELECT
  CustomerID,
  purchase_cnt, -- Frequency (주문 횟수)
  recency,      -- Recency (마지막 구매 후 경과일)
  user_total    -- Monetary (총 지출액)
FROM modulabs_project.user_rfm
ORDER BY CustomerID;
```

행	CustomerID	purchase_cnt	recency	user_total
1	12346	2	325	0.0
2	12347	7	2	4310.0
3	12348	4	75	1437.0
4	12349	1	18	1458.0
5	12350	1	310	294.0
6	12352	8	36	1265.0
7	12353	1	204	89.0
8	12354	1	232	1079.0
9	12355	1	214	459.0

11-8. 추가 Feature 추출

▼ 1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2) `user_rfm` 테이블과 결과를 합치기
  3) `user_data` 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
  FROM modulabs_project.data
  GROUP BY CustomerID
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM modulabs_project.user_rfm AS ur
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

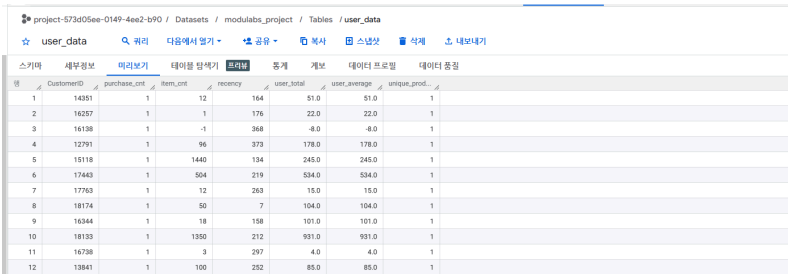

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_prod...
1	14351	1	12	164	51.0	51.0	1
2	16257	1	1	176	22.0	22.0	1
3	16138	1	-1	368	-8.0	-8.0	1
4	12791	1	96	373	178.0	178.0	1
5	15118	1	1440	134	245.0	245.0	1
6	17443	1	504	219	534.0	534.0	1
7	17763	1	12	263	15.0	15.0	1
8	18174	1	50	7	104.0	104.0	1
9	16344	1	18	158	101.0	101.0	1
10	18133	1	1350	212	931.0	931.0	1
11	16738	1	3	297	4.0	4.0	1
12	13841	1	100	252	85.0	85.0	1

▼ 2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**

- **평균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합**

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH purchase_intervals AS (
 -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
 SELECT
  CustomerID,
  CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
 FROM (
  -- (1) 구매와 구매 사이에 소요된 일수
  SELECT
   CustomerID,
   DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
  FROM
   modulabs_project.data
  WHERE CustomerID IS NOT NULL
 )
 GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

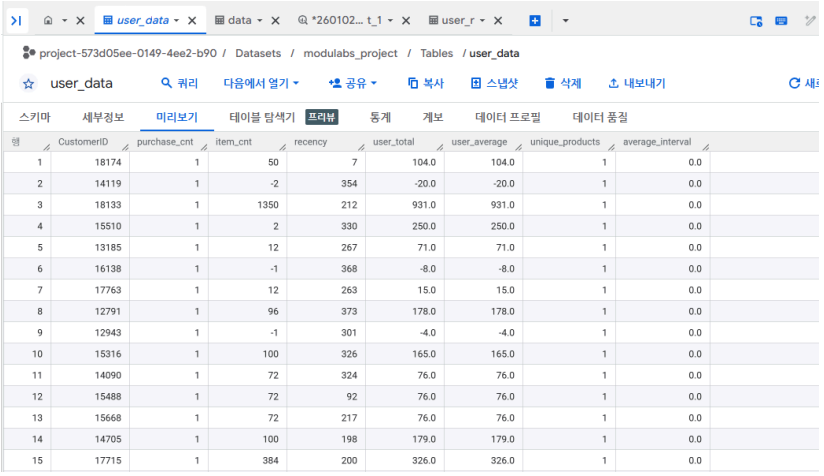

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval
1	18174	1	50	7	104.0	104.0	1	0.0
2	14119	1	-2	354	-20.0	-20.0	1	0.0
3	18133	1	1350	212	931.0	931.0	1	0.0
4	15510	1	2	330	250.0	250.0	1	0.0
5	13185	1	12	267	71.0	71.0	1	0.0
6	16138	1	-1	368	-8.0	-8.0	1	0.0
7	17763	1	12	263	15.0	15.0	1	0.0
8	12791	1	96	373	178.0	178.0	1	0.0
9	12943	1	-1	301	-4.0	-4.0	1	0.0
10	15316	1	100	326	165.0	165.0	1	0.0
11	14090	1	72	324	76.0	76.0	1	0.0
12	15488	1	72	92	76.0	76.0	1	0.0
13	15668	1	72	217	76.0	76.0	1	0.0
14	14705	1	100	198	179.0	179.0	1	0.0
15	17715	1	384	200	326.0	326.0	1	0.0

▼ 3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
  2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
  - **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기**
    (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS

WITH TransactionInfo AS (
 SELECT
  CustomerID,
  COUNT(DISTINCT InvoiceNo) AS total_transactions, -- 전체 거래 건수
  COUNT(DISTINCT CASE WHEN InvoiceNo LIKE 'C%' THEN InvoiceNo END) AS cancel_frequency -- 취소된 거래 건수
 FROM modulabs_project.data
 GROUP BY CustomerID
)

SELECT u.*, t.* EXCEPT(CustomerID),
  ROUND(SAFE_DIVIDE(t.cancel_frequency, t.total_transactions), 2) AS cancel_rate -- 취소 비율 (취소 건수 / 전체 건수)
```

```
FROM modulabs_project.user_data AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```

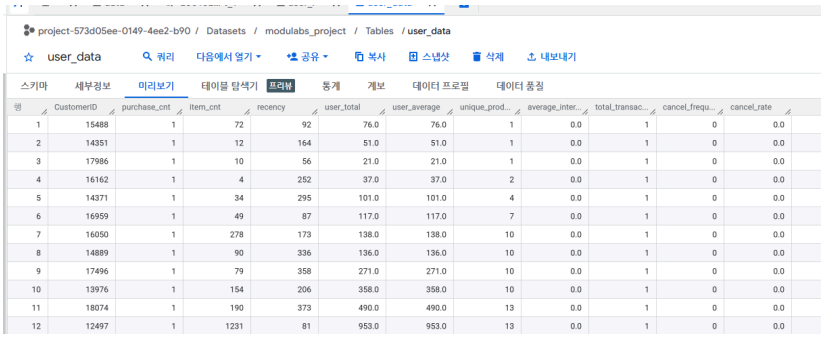

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_prod...	average_inter...	total_transac...	cancel_frequ...	cancel_rate
1	15488	1	72	92	76.0	76.0	1	0.0	1	0	0.0
2	14351	1	12	164	51.0	51.0	1	0.0	1	0	0.0
3	17986	1	10	56	21.0	21.0	1	0.0	1	0	0.0
4	16162	1	4	252	37.0	37.0	2	0.0	1	0	0.0
5	14371	1	34	295	101.0	101.0	4	0.0	1	0	0.0
6	16959	1	49	87	117.0	117.0	7	0.0	1	0	0.0
7	16050	1	278	173	138.0	138.0	10	0.0	1	0	0.0
8	14889	1	90	336	136.0	136.0	10	0.0	1	0	0.0
9	17496	1	79	358	271.0	271.0	10	0.0	1	0	0.0
10	13976	1	154	206	358.0	358.0	10	0.0	1	0	0.0
11	18074	1	190	373	490.0	490.0	13	0.0	1	0	0.0
12	12497	1	1231	81	953.0	953.0	13	0.0	1	0	0.0

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
SELECT
  CustomerID,
  recency, purchase_cnt, user_total,
  user_average, item_cnt,
  average_interval,
  total_transactions, cancel_frequency, cancel_rate
FROM modulabs_project.user_data
ORDER BY user_total DESC; -- 가장 기여도가 높은 고객부터 확인
```

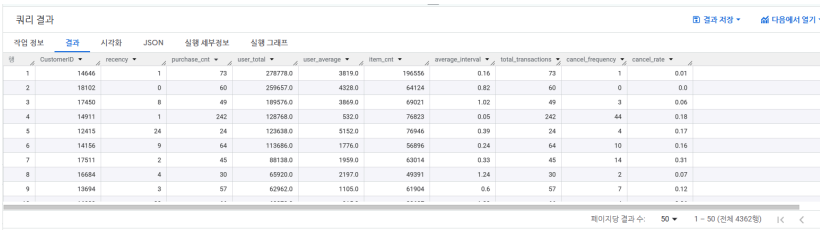

행	CustomerID	recency	purchase_cnt	user_total	user_average	item_cnt	average_interval	total_transactions	cancel_frequency	cancel_rate
1	14646	1	73	278778.0	3819.0	196556	0.16	73	1	0.01
2	18102	0	60	259657.0	4328.0	64124	0.82	60	0	0.0
3	17450	8	49	189576.0	3869.0	69021	1.02	49	3	0.06
4	14911	1	242	128768.0	532.0	76823	0.05	242	44	0.18
5	12415	24	24	123638.0	5152.0	76946	0.39	24	4	0.17
6	14156	9	64	113686.0	1776.0	56896	0.24	64	10	0.16
7	17511	2	45	88138.0	1959.0	63014	0.33	45	14	0.31
8	16684	4	30	65920.0	2197.0	49391	1.24	30	2	0.07
9	13694	3	57	62962.0	1105.0	61904	0.6	57	7	0.12

회고

💡 **"에러 나면 → 괄호의 위치, 쉼표의 유무, 중복된 컬럼명 부터 확인하자!"**

▼ 📝 Keep (배울점 or 유지해야 할 좋은 습관)

- **단계별 테이블 생성 및 저장:** `user_r` , `user_rf` , `user_rfm` 순으로 단계별 결과를 테이블로 저장, 복잡한 로직 단순화
- **에러 메시지 기반의 문제 해결:** `duplicate name` 이나 `aggregate function` 에러 발생 시 원인을 분석하고 `EXCEPT` , `REPLACE` 등의 문법으로 해결함

▼ ⚠️ Problem (초심자가 겪은 주요 실수 및 어려움)

- **★ 집계 함수와 일반 컬럼 혼용:** `SELECT` **절에** `MAX()` **와 같은 집계 함수와 일반 컬럼을 동시에 쓸 때 발생하는 그룹화 오류(Grouping error) 유의해야함**
- **함수 괄호 및 인자 위치 실수 및 오탈자 등**
  - `ROUND(SUM(A * B, 0))` 와 같이 중첩 함수 사용 시 괄호 위치를 잘못 지정하여 `No matching signature` 에러 발생
  - `SELECT` 목록 마지막 컬럼 뒤에 불필요한 쉼표(`,`)를 남겨 구문 오류가 발생함.
- **나눗셈 에러 처리:** `cancel_rate` 계산 시 분모가 0이 될 수 있는 경우에 대한 예외 처리(`SAFE_DIVIDE`) 필요함, 향후 실수 없도록 할 필요 있음

▼ 🚀 Try (향후 적용할 복습 포인트 및 개선안)

- **윈도우 함수(`OVER()`) 활용 숙달**: 집계와 상세 내역을 동시에 보고 싶을 때는 `GROUP BY` 대신 윈도우 함수를 사용하여 행의 수를 유지하는 방식을 적극 활용할 것
- **고급 컬럼 제어 문법 활용**: 컬럼 중복 문제를 해결하기 위해 `EXCEPT` 로 특정 컬럼을 제외하거나, `REPLACE` 로 특정 컬럼만 덮어쓰는 방식을 습관화할 것
- **데이터 무결성 검증**: `COUNT(DISTINCT InvoiceNo)` 와 같이 '고유 건수'를 세는 로직과 일반 `COUNT` 의 차이를 명확히 구분하여 데이터 왜곡 방지할 것
- **예외 케이스 고려**: 나눗셈 연산 시에는 반드시 `SAFE_DIVIDE` 를 사용하고, `NULL` 값은 `CASE WHEN` 이나 `COALESCE` 로 0점 처리를 명시할 것
- **결과 조회 시 검토 우선순위 염두**: 최종 결과 조회 시에는 `ORDER BY` 를 통해 검토할 필요성이 높은 (예: 지출액 상위) 데이터를 먼저 확인하는 버릇 필요